Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»

Домашнее задание №3

по дисциплине

«Инженерия данных»

Выполнила:
Смирнова Анна Андреевна
ИСУ: 467514
Группа: J3311

Санкт-Петербург
2026

1 Развертывание хранилища и загрузка данных (Этапы 1–2)

Развернуто S3-совместимое хранилище RustFS. Создан бакет `hh-lake`, куда загружен датасет `it_vacancies_2024` (≈ 808.3 МБ):

```
C:\Users\LENOVO>cd C:\Users\LENOVO\Desktop\ITMO_labs\Data_engineering_vk

C:\Users\LENOVO\Desktop\ITMO_labs\Data_engineering_vk>docker compose up -d rustfs1 r
ustfs2 rustfs3 rustfs4 s3cli
[+] up 6/6
 ✔ Network hh-stand_stand Created                                          0.2s
 ✔ Container hh-rustfs3   Started                                          3.8s
 ✔ Container hh-rustfs1   Started                                          2.6s
 ✔ Container hh-rustfs2   Started                                          4.3s
 ✔ Container hh-rustfs4   Started                                          1.8s
 ✔ Container hh-s3cli     Started                                          2.7s

C:\Users\LENOVO\Desktop\ITMO_labs\Data_engineering_vk>docker exec -it hh-s3cli bash
bash-5.2# aws s3 mb s3://hh-lake
make_bucket: hh-lake
bash-5.2# aws s3 cp /course/it_vacancies_2024.csv s3://hh-lake/
upload: ../course/it_vacancies_2024.csv to s3://hh-lake/it_vacancies_2024.csv
bash-5.2# aws s3 ls s3://hh-lake/
2026-10-19 18:41:02  847619384 it_vacancies_2024.csv
bash-5.2#
```

Рис. 1: Создание бакета hh-lake и размещение датасета в RustFS

2 Подсчет навыков, комбинаторика и верификация (Этапы 3–4)

Фильтрация целевого сегмента: роль содержит `'ПРОГРАММИСТ'`, имя — `'1С'`.

- **MapReduce:** построковое чтение чанков из S3 через `boto3`, генерация одиночных навыков, пар и троек через `itertools.combinations`. Результаты выгружены в S3.
- **DuckDB:** прямой SQL-запрос к S3 с использованием `UNNEST(string_split(key_skills, ';'))`.

Объяснение роста числа сочетаний: Число генерируемых пар и троек растет лавинообразно по формуле $C_N^k = \frac{N!}{k!(N-k)!}$. При среднем числе навыков $N = 6$: одиночных $C_6^1 = 6$, пар $C_6^2 = 15$ (рост в 2.5 раза), троек $C_6^3 = 20$ (рост в 3.3 раза). Это создает колоссальную нагрузку на стадию *Shuffle*, требуя предварительной агрегации комбайнером.

Навык (Стек 1)	**MapReduce**	**DuckDB**
1С программирование	8 278	8 278
1С: Предприятие 8	4 414	4 414
1С: Бухгалтерия	2 781	2 781
1С: Управление Торговлей	2 530	2 530
ERP-системы на базе 1С	2 335	2 335

Таблица 1: Верификация: 100% совпадение контрольных чисел MapReduce и DuckDB

```
=== ВЕРИФИКАЦИЯ РЕЗУЛЬТАТОВ ===
Топ-5 навыков MapReduce: [('1С программирование', 8278), ('1С: Предприятие 8', 4414)
, ('1С: Бухгалтерия', 2781), ('1С: Управление Торговлей', 2530), ('ERP-системы на ба
зе 1С', 2335)]
Топ-5 навыков DuckDB:    [('1С программирование', 8278), ('1С: Предприятие 8', 4414)
, ('1С: Бухгалтерия', 2781), ('1С: Управление Торговлей', 2530), ('ERP-системы на ба
зе 1С', 2335)]
-> УСПЕХ: Данные полностью совпадают!
```

Рис. 2: Успешная верификация

```
C:\Users\LENOVO\Desktop\ITMO_labs\Data_engineering_vk>docker exec -it hh-s3cli aws s3 ls s3://hh-lake/
2026-10-19 18:41:02  847619384 it_vacancies_2024.csv
2026-10-19 19:13:33      51406 mapreduce_1c_results.json
```

Рис. 3: Содержимое бакета hh-lake в S3: исходный датасет и результаты работы MapReduce

3 Профилирование производительности (3 запуска)

Запуск	Время MR (с)	Память MR (МБ)	Время DuckDB (с)	Память DuckDB (МБ)
1	45.90	68.47	13.24	0.00 (C++)
2	44.07	68.47	9.35	0.00 (C++)
3	46.64	68.47	8.88	0.00 (C++)
Среднее	**45.54 с**	**68.47 МБ**	**10.49 с**	—

Таблица 2: Сравнение производительности подходов

Вывод: Потоковый MapReduce строго держит память на уровне 68.47 МБ на файле в 800+ МБ, но уступает DuckDB по скорости в 4.3 раза из-за накладных расходов Python. DuckDB выигрывает за счет векторизации на C++.

4 Анализ влияния навыков на заработную плату (Этап 5)

Базовая медианная зарплата разработчика 1С: **140 000 руб.**

Тип	Набор навыков	Медиана	Сдвиг Δ	Вакансий
TOP+	1С прогр. + Налоговое законодательство	325 000 руб.	**+185 000**	6
	1С: ЗУП + 1С: Предприятие + Бухгалтерская отчетность	350 000 руб.	**+210 000**	5
	1С: Бухгалтерия + 1С:ERP + Бухгалтерская отчетность	350 000 руб.	**+210 000**	5
TOP–	1С: Предприятие + Обучение и развитие	13 000 руб.	**–127 000**	7
	1С прогр. + Мотивация	13 000 руб.	**–127 000**	5
	1С прогр. + Обучение и развитие + Ориентация на результат	13 000 руб.	**–127 000**	6

Таблица 3: Пары и тройки навыков с наибольшим влиянием на доход

Инсайты:

- **Повышение (Δ до +210 тыс. руб.):** Знание предметной области (*Налоговое право, Бухотчетность*) и тяжелых систем (*1С:ERP, ЗУП*) переводит разработчика в ранг ведущего архитектора бизнес-систем.
- **Понижение (Δ до –127 тыс. руб.):** Зарплаты 13 000–20 000 руб. вызваны не низким рынком, а спецификой стажерских позиций (Intern), студенческой практики и неполных ставок (0.25 ставки) с общими soft-skills требованиями.

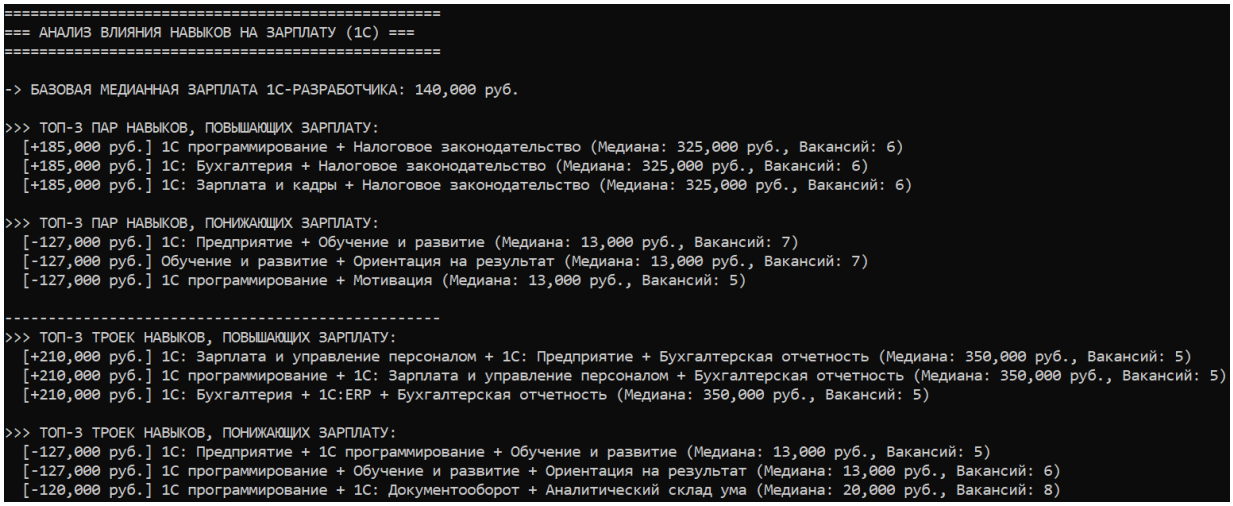


Рис. 4: Вывод консоли по зарплатному анализу

5 Региональный анализ (Этап 6)

Сравнение трех контрастных субъектов РФ: Москвы, Санкт-Петербурга и Якутска.

Регион	Всего вакансий	Вакансий с ЗП	Медиана ЗП	Топ-3 востребованных навыка
Москва	5 048	2 063	**200 000 руб.**	1С прогр., 1С: Предприятие, ERP
СПб	1 615	822	**150 000 руб.**	1С прогр., 1С: Предприятие, Торговля
Якутск	12	7	**80 000 руб.**	1С прогр., Торговля, ЗУП

Таблица 4: Сводные региональные показатели и востребованность стека

Инсайты по регионам:

1. **Москва** лидирует по объему и зарплатам. Только здесь в топ-3 входит внедрение крупных корпоративных систем (*ERP*).
2. **Санкт-Петербург** ориентирован на ритейл и логистику (*Управление Торговлей*), формируя зрелый рынок со стабильной медианой в 150 тыс. руб.
3. **Якутск** представляет изолированный малый рынок ($N = 12$). Крупных внедрений ERP нет, спрос сосредоточен на поддержке торговых точек и кадрового учета (ЗУП) локальных предприятий.

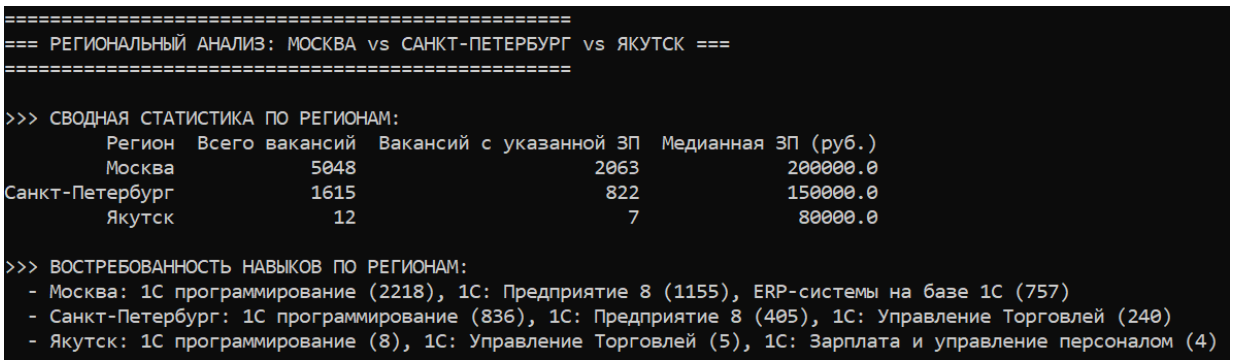


Рис. 5: Вывод региональной статистики

6 Заключение (Этап 7)

В ходе выполнения лабораторной работы был успешно развернут аналитический пайплайн для обработки больших данных. В объектном хранилище RustFS создан бакет hh-lake и загружен датасет ИТ-вакансий. Реализован собственный MapReduce-алгоритм, осуществляющий потоковое чтение чанков из S3, фильтрацию по варианту («Программист 1С») и комбинаторный расчет частот одиночных навыков, пар и троек. Проведенное профилирование показало высокую эффективность потокового MapReduce по потреблению памяти (стабильные 68.47 МБ), в то время как реляционный движок DuckDB продемонстрировал превосходство по скорости выполнения (в 4.3 раза быстрее). Верификация подтвердила совпадение результатов обоих методов, а итоговые агрегаты успешно сохранены в S3. На основе построенных витрин данных выявлены ключевые зарплатные инсайты (влияние архитектурных стеков и стажерских позиций) и проведено региональное сопоставление рынков труда Москвы, Санкт-Петербурга и Якутска.

Код скрипта, конфигурация и данный PDF загружены в репозиторий: ссылка на Github